École Supérieure d'Ingénierie en Sciences Appliquées

Ingénierie des Systèmes d'Information & Intelligence Artificielle

Data analytics

Projet : Les taxis à Chicago (US)

Réalisé par :

Boutayeb Marouane

BELFAKIR Abdelfettah

ES-SAIDI Anass

Encadré par : Pr. HDIOUD Ferdaous



A.U : 2025-2026

Table des matières

1 Introduction et Description du Sujet **1**

2 Présentation du Dataset **1**

2.1 Collecte des données 1

3 Description et Prétraitement des Données **2**

3.1 Préparation et fusion des données 2

3.2 Étapes de prétraitement 2

3.3 Statistiques descriptives 3

3.4 Évolution annuelle 4

4 Méthodologie **5**

4.1 Question 1 — Test t de Student 5

4.2 Question 2 — Corrélation et Régression linéaire 6

4.3 Question 3 — ANOVA, test post-hoc et corrélation par plage horaire 6

5 Résultats et Interprétation **6**

5.1 Question 1 : Test d'hypothèse sur la moyenne de P, D et L ($\alpha = 5\,\%$) 6

5.2 Question 2 : Relation entre Prix, Longueur et Durée 7

5.3 Question 3 : Plages horaires et plage de pointe 8

5.4 Test post-hoc de Bonferroni 9

6 Conclusion **11**

6.1 Limites de l'étude 11

1. Introduction et Description du Sujet

Ce projet s'inscrit dans le cadre du cours d'*Analyse de Données*. Il porte sur l'étude des courses de taxi de la ville de **Chicago** (Illinois, États-Unis), disponibles sur le portail officiel `data.cityofchicago.org` (dataset *Taxi Trips*, identifiant : `wrvz-psew`).

La base de données recense l'ensemble des courses effectuées par les taxis de la ville depuis 2013. Les trois variables d'intérêt sont :

- P — **Prix total** (`trip_total`, en dollars \$) ;
- D — **Durée** (`trip_seconds`, en secondes) ;
- L — **Longueur** (`trip_miles`, en miles).

L'objectif est de répondre aux trois questions statistiques suivantes :

1. Tester si la moyenne de P, D et L change significativement en 2021 par rapport à la période 2013–2020 (test à $\alpha = 5\,\%$).
2. Étudier la relation entre le prix P et les variables L et D (corrélation et régression linéaire).
3. Identifier une plage horaire de pointe et tester la corrélation linéaire entre P et la plage horaire (nécessite les horodatages).

2. Présentation du Dataset

Les données utilisées dans ce projet proviennent du dataset public *Chicago Taxi Trips*. Cette base contient les informations des trajets de taxis effectués dans la ville de Chicago entre 2013 et 2023. Les principales variables utilisées dans cette étude sont :

- `trip_total` : prix total de la course (tarif, pourboire, péages et suppléments) ;
- `trip_seconds` : durée du trajet en secondes ;
- `trip_miles` : distance parcourue en miles ;
- `trip_start_timestamp` : date et heure de départ ;
- `trip_end_timestamp` : date et heure d'arrivée.

Les horodatages sont exprimés en heure locale de Chicago et arrondis au quart d'heure.

2.1. Collecte des données

Les données ont été extraites de la table publique BigQuery, copie du portail Open Data de la ville (script `PRE/01_download.py`) :

`bigquery-public-data.chicago_taxi_trips.taxi_trips`

Le dataset original est extrêmement volumineux : il contient plusieurs centaines de millions de trajets couvrant les années 2013 à 2023, pour une taille totale qui dépasse 20 Go. Le téléchargement complet était difficile à cause :

- des limitations de l'API ;
- des erreurs de type `Timeout` ;
- des temps de téléchargement très longs ;
- des limitations de mémoire et de stockage.

Afin de rendre les traitements statistiques réalisables dans des conditions raisonnables, un **échantillonnage aléatoire** a été effectué : pour chaque année entre 2013 et 2023, environ 108 000 trajets ont été tirés au hasard. Le dataset final est donc un sous-ensemble représentatif des données originales, de taille exploitable pour les analyses statistiques en Python.

Les fichiers obtenus sont : `{2013.csv, 2014.csv, ..., 2023.csv}`. Chaque fichier contient les colonnes `trip_total`, `trip_seconds`, `trip_miles`, `trip_start_timestamp` et `trip_end_timestamp`. Le nombre de lignes et la taille de chaque fichier sont présentés dans le tableau 1.

Table 1 : Nombre de lignes et taille des fichiers CSV par année

Fichier	Nombre de lignes	Taille (Mo)
2013.csv	108 900	8,01
2014.csv	107 740	8,19
2015.csv	107 820	8,17
2016.csv	106 920	8,20
2017.csv	107 097	8,18
2018.csv	106 907	8,19
2019.csv	106 706	8,19
2020.csv	106 676	8,18
2021.csv	106 490	8,18
2022.csv	106 388	8,20
2023.csv	106 293	8,21
Total	**1 177 937**	**≈ 90**

3. Description et Prétraitement des Données

3.1. Préparation et fusion des données

Avant tout traitement statistique, les 11 fichiers CSV ont été fusionnés en un seul fichier `chicago_taxi_raw.csv` à l'aide du script `PRE/02_fusion.py`. Une attention particulière a été portée au **séparateur décimal** : les fichiers utilisent la virgule comme séparateur décimal (format français), par exemple `"0,01"`. La conversion a été effectuée en lisant les colonnes numériques comme chaînes de caractères, puis en remplaçant la virgule par un point avant la conversion numérique :

```
df[col] = df[col].str.replace(',', '.', regex=False)
df[col] = pd.to_numeric(df[col], errors='coerce')
```

Une colonne `year` a également été ajoutée lors de la fusion pour identifier l'année d'origine de chaque trajet.

3.2. Étapes de prétraitement

Le prétraitement est réalisé par le script `PRE/03_preprocess.py` :

1. **Chargement** : 11 fichiers CSV (2013–2023) fusionnés en **1 177 937 lignes** brutes.

2. **Suppression des valeurs manquantes ou nulles** ($P \leq 0$, $D \leq 0$, $L \leq 0$) : 180 216 lignes supprimées.
3. **Filtres de plausibilité** : 15 257 lignes supprimées. On ne conserve que les courses avec $P \geq 3{,}25\,\$$ (prise en charge minimale d'un taxi à Chicago), $D \geq 60\,\text{s}$, $L \geq 0{,}1\,\text{mile}$ et une vitesse moyenne $L/D \leq 80\,\text{mph}$. Ces filtres éliminent les erreurs de saisie (prix de 0,01 \$, courses d'une seconde, vitesses impossibles).
4. **Suppression des *outliers*** par la méthode IQR (facteur $k = 3$) sur P, D et L : 6 525 lignes supprimées.
5. **Variables dérivées** : heure de départ, numéro de plage horaire (0 à 5), libellé de la plage et durée en minutes.
6. **Résultat final** : **975 939 courses** valides.
7. **Séparation** : 2013–2020 en ensemble de référence (692 502 courses) et 2021 en ensemble test (94 792 courses).

Méthode IQR

Pour chaque variable X, on calcule Q_1 et Q_3, puis :

$$X \text{ conservé si } \quad Q_1 - 3 \cdot \text{IQR} \;\leq\; X \;\leq\; Q_3 + 3 \cdot \text{IQR} \qquad \text{avec} \quad \text{IQR} = Q_3 - Q_1$$

Les bornes supérieures obtenues sont 140,57 \$ pour P, 5 715 s pour D et 50,70 miles pour L. Les distributions étant très asymétriques, les bornes inférieures sont **négatives** : la méthode IQR ne supprime donc aucune valeur trop petite, d'où la nécessité des filtres de plausibilité de l'étape 3.

3.3. Statistiques descriptives

Le tableau 2 présente les principales statistiques de P, D et L pour les deux sous-ensembles après prétraitement.

Table 2 : Statistiques descriptives des variables P, D et L après prétraitement

Variable	Période	n	Moyenne	Écart-type	Médiane
P (\$)	Référence (2013–2020)	692 502	29,04	19,54	22,50
P (\$)	Test (2021)	94 792	34,51	19,35	29,75
D (s)	Référence (2013–2020)	692 502	1 452,1	955,5	1 260,0
D (s)	Test (2021)	94 792	1 536,3	799,0	1 405,0
L (miles)	Référence (2013–2020)	692 502	8,34	6,98	5,90
L (miles)	Test (2021)	94 792	9,54	6,66	8,94

Les trois distributions sont asymétriques à droite (médiane inférieure à la moyenne). La distribution de L présente un second mode autour de 17–18 miles, qui correspond aux trajets vers les aéroports.

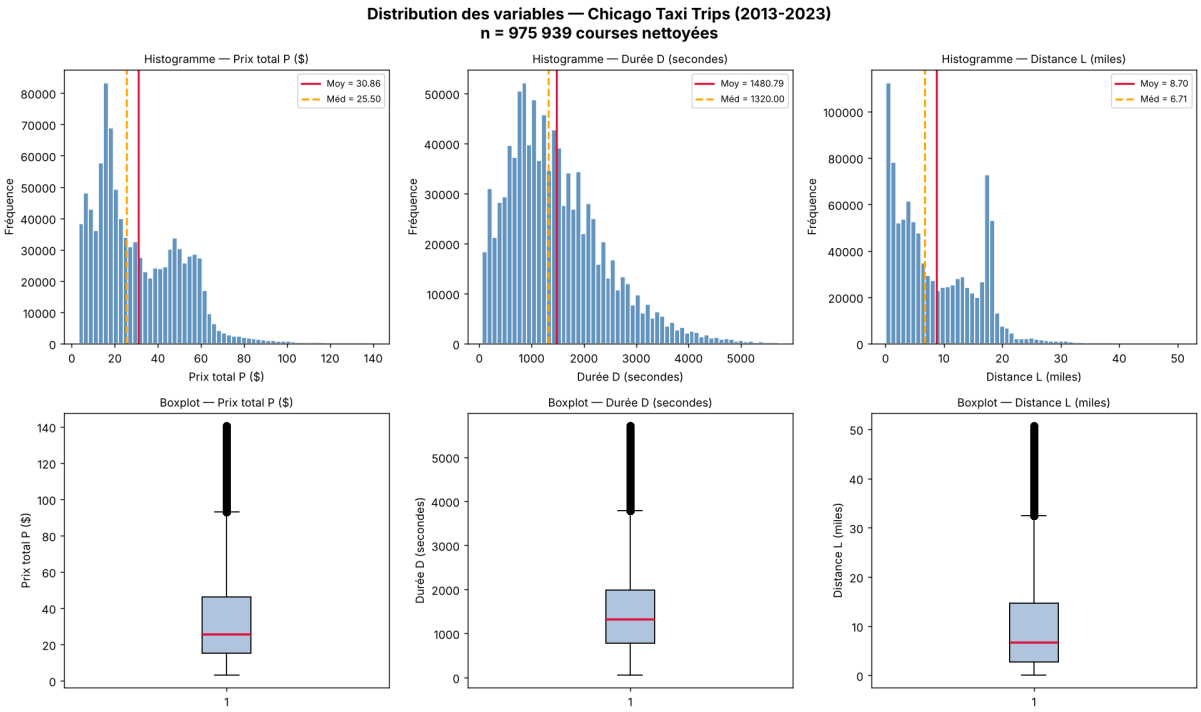


Figure 1 : Histogrammes et boxplots de P (trip_total), D (trip_seconds) et L (trip_miles)

3.4. Évolution annuelle

Le tableau 3 et la figure 2 montrent l'évolution des moyennes annuelles. Le prix moyen passe de 19,79 $ en 2013 à 34,87 $ en 2019, avec une rupture nette entre 2015 (22,63 $) et 2016 (29,98 $) : la distance moyenne passe dans le même temps de 6,93 à 9,25 miles, ce qui traduit une baisse de la part des courses courtes. L'année 2020 marque un creux (31,33 $), puis les valeurs de 2021 reviennent au niveau de 2019.

Table 3 : Nombre de courses retenues et moyennes annuelles de P, D et L

Année	n	$\bar{P}$ **($)**	$\bar{D}$ **(s)**	$\bar{L}$ **(miles)**
2013	39 664	19,79	1 144,1	5,28
2014	87 854	20,57	1 223,5	6,29
2015	82 820	22,63	1 340,0	6,93
2016	100 102	29,98	1 430,3	9,25
2017	95 871	32,40	1 542,5	9,27
2018	96 324	33,79	1 613,0	9,44
2019	94 601	34,87	1 644,6	9,40
2020	95 266	31,33	1 466,4	8,66
2021	94 792	34,51	1 536,3	9,54
2022	93 720	35,27	1 546,0	9,52
2023	94 925	36,17	1 570,3	9,65

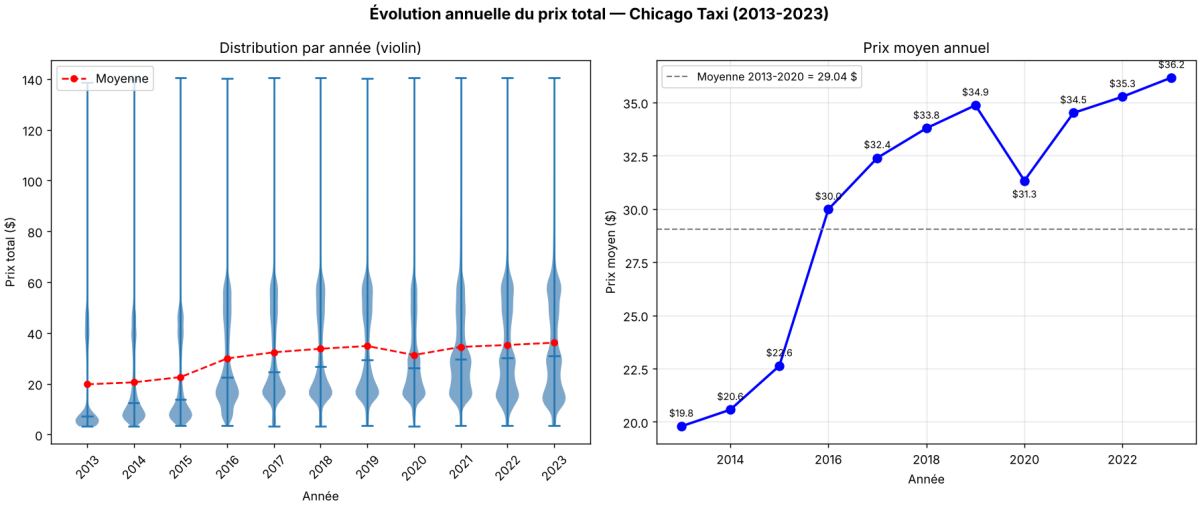


Figure 2 : Évolution annuelle du prix de 2013 à 2023 (violin plots et prix moyen annuel)

4. Méthodologie

Le pipeline suivi est :

Collecte ⟶ **Prétraitement** ⟶ **Transformation** ⟶ **Analyse** ⟶ **Visualisation**

4.1. Question 1 — Test t de Student

Pour tester si la moyenne d'une variable $X \in \{P, D, L\}$ diffère entre la période de référence et l'échantillon test, on utilise le **test t à un échantillon bilatéral** :

$$H_0 : \mu_{\text{test}} = \mu_{\text{ref}} \qquad \text{vs} \qquad H_1 : \mu_{\text{test}} \neq \mu_{\text{ref}}$$

La statistique de test est :

$$t = \frac{\bar{X}_{\text{test}} - \mu_{\text{ref}}}{s_{\text{test}} / \sqrt{n_{\text{test}}}} \quad \sim \quad t(n_{\text{test}} - 1)$$

On rejette H_0 si $|t| > t_{\alpha/2,\, n-1}$, c'est-à-dire si la p-valeur est inférieure à $\alpha = 0{,}05$.

Justification : la moyenne 2013–2020, calculée sur 692 502 courses, sert de valeur de référence μ_{ref}. Le théorème central limite garantit la normalité de $\bar{X}$ pour $n > 30$ (ici $n = 94\,792$).

Compléments :

- La référence étant elle-même un échantillon, le résultat est vérifié par un **test t de Welch** à deux échantillons (2021 vs 2013–2020), qui n'impose pas l'égalité des variances.
- Avec près de 10^5 observations, un écart très faible suffit à rejeter H_0. L'importance pratique de l'écart est donc mesurée par le d **de Cohen** : $d = (\bar{X}_{2021} - \bar{X}_{\text{ref}})/s_p$, où s_p est l'écart-type combiné ($|d| < 0{,}2$: effet négligeable ; 0,2 à 0,5 : faible ; 0,5 à 0,8 : moyen).
- Pour séparer l'effet de l'année 2021 de la tendance de long terme, 2021 est aussi comparée à 2019, dernière année avant la pandémie.

4.2. Question 2 — Corrélation et Régression linéaire

La **corrélation de Pearson** mesure la force de la liaison linéaire entre P et chaque variable explicative :

$$r(P, X) = \frac{\sum_i (P_i - \bar{P})(X_i - \bar{X})}{\sqrt{\sum_i (P_i - \bar{P})^2} \cdot \sqrt{\sum_i (X_i - \bar{X})^2}}$$

La **régression linéaire simple** $P = \beta_0 + \beta_1 X + \varepsilon$ est estimée par moindres carrés ordinaires (MCO). La **régression multiple** $P = \beta_0 + \beta_1 L + \beta_2 D + \varepsilon$ combine les deux variables.

Justification : les variables sont continues et les nuages de points révèlent une tendance linéaire. Le R^2 quantifie la part de variance du prix expliquée par le modèle.

4.3. Question 3 — ANOVA, test post-hoc et corrélation par plage horaire

La journée est divisée en 6 tranches de 4 heures : [00h–04h[, [04h–08h[, [08h–12h[, [12h–16h[, [16h–20h[, [20h–00h[. L'**ANOVA à un facteur** teste l'égalité des moyennes de P entre les 6 groupes :

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_6 \qquad \text{vs} \qquad H_1 : \exists\, i \neq j,\ \mu_i \neq \mu_j$$

La taille d'effet est mesurée par $\eta^2 = SC_{\text{inter}}/SC_{\text{totale}}$, part de la variance du prix expliquée par la plage horaire.

Test post-hoc de Bonferroni : l'ANOVA indique seulement qu'au moins un groupe diffère. Pour identifier *quelles* plages diffèrent significativement entre elles, on effectue des tests t par paires avec correction de Bonferroni ($\alpha_{\text{corr}} = 0{,}05/15 \approx 0{,}0033$). Ceci permet d'identifier formellement la plage de pointe.

La corrélation de Pearson $r(P, \text{slot})$ teste la tendance linéaire monotone du prix en fonction du numéro de plage.

Justification : l'ANOVA évite l'inflation du risque d'erreur de type I inhérente aux tests t par paires multiples. La correction de Bonferroni contrôle le taux d'erreur global.

5. Résultats et Interprétation

5.1. Question 1 : Test d'hypothèse sur la moyenne de P, D et L ($\alpha = 5\,\%$)

Table 4 : Résultats du test t bilatéral ($\alpha = 5\,\%$) — 2021 vs 2013–2020

Variable	μ_{ref}	$\bar{X}_{2021}$	t	p-valeur	t Welch	d	Variation
P (trip_total, \$)	29,04	34,51	+87,05	≈ 0	+81,55	0,28	+18,8 %
D (trip_seconds, s)	1 452,1	1 536,3	+32,47	$5{,}04 \times 10^{-230}$	+29,69	0,09	+5,8 %
L (trip_miles)	8,34	9,54	+55,41	≈ 0	+51,66	0,17	+14,4 %
Décision : rejeter H_0 pour les trois variables (p-valeur $\ll \alpha = 0{,}05$)							

Les trois variables présentent un écart statistiquement significatif en 2021 par rapport à la référence 2013–2020, confirmé par le test de Welch :

- **Prix (P) :** la moyenne passe de 29,04 \$ à 34,51 \$, soit +5,47 \$ (+18,8 %), avec $t = 87{,}05$. L'effet est **faible** ($d = 0{,}28$).

- **Durée (D) :** la durée moyenne passe de 1 452,1 s à 1 536,3 s, soit +84,3 s (+5,8 %), avec $t = 32{,}47$ et $p = 5{,}04 \times 10^{-230}$. L'effet est **négligeable** ($d = 0{,}09$).
- **Distance (L) :** la distance moyenne passe de 8,34 à 9,54 miles, soit +1,20 mile (+14,4 %), avec $t = 55{,}41$. L'effet est **négligeable** ($d = 0{,}17$).

Interprétation : la significativité s'explique en grande partie par la taille des échantillons ; les tailles d'effet restent faibles. Surtout, la référence 2013–2020 mélange des années très différentes : le prix moyen passe de 19,79 $ en 2013 à 34,87 $ en 2019 (tableau 3). La hausse observée en 2021 traduit donc d'abord la **tendance de long terme**, et non un effet propre à l'année 2021. Le tableau 5 le confirme en comparant 2021 à 2019.

Table 5 : Analyse complémentaire — 2021 vs 2019 (test de Welch, $n_{2019} = 94\,601$, $n_{2021} = 94\,792$)

Variable	$\bar{X}_{2019}$	$\bar{X}_{2021}$	Variation	t	p-valeur	d
P (trip_total, $)	34,87	34,51	−1,0 %	−3,99	$6{,}64 \times 10^{-5}$	−0,018
D (trip_seconds, s)	1 644,6	1 536,3	−6,6 %	−27,11	$1{,}38 \times 10^{-161}$	−0,125
L (trip_miles)	9,40	9,54	+1,5 %	+4,46	$8{,}32 \times 10^{-6}$	+0,020

Par rapport à 2019, le prix moyen de 2021 est quasiment identique (−1,0 %, $d = -0{,}018$) et la distance aussi (+1,5 %, $d = +0{,}020$). Le seul changement notable est une **baisse de la durée** (−6,6 %, $d = -0{,}125$) pour des distances comparables, ce qui est compatible avec une circulation moins dense en 2021, pendant la pandémie de COVID-19. Ces écarts restent toutefois d'ampleur négligeable.

5.2. Question 2 : Relation entre Prix, Longueur et Durée

Corrélations de Pearson

$$r(P, L) = 0{,}845 \quad (p \approx 0) \qquad\qquad r(P, D) = 0{,}714 \quad (p \approx 0)$$

La liaison entre P et L est **forte** ($r = 0{,}845$) ; celle entre P et D est **modérée à forte** ($r = 0{,}714$). Les p-valeurs sont en sous-dépassement numérique ($< 2{,}2 \times 10^{-308}$), ce qui confirme une significativité extrême pour $n = 975\,939$. Les deux variables explicatives sont elles-mêmes corrélées : $r(L, D) = 0{,}659$.

Modèles de régression (MCO sur 975 939 courses)

Table 6 : Résultats des modèles de régression linéaire

Modèle	Équation estimée (MCO)	R^2
$P \sim L$	$\hat{P} = 9{,}73 + 2{,}430 \cdot L$	0,714
$P \sim D$	$\hat{P} = 8{,}12 + 0{,}01536 \cdot D$	0,510
$P \sim L + D$	$\hat{P} = 5{,}45 + 1{,}902 \cdot L + 0{,}005994 \cdot D$	**0,758**

La régression simple $P \sim L$ explique **71,4 %** de la variance du prix ; la durée seule ($P \sim D$) en explique 51,0 %. L'ajout de D dans le modèle $P \sim L + D$ porte le R^2 à **0,758**, soit un gain

de 4,4 points de pourcentage : distance et durée sont deux facteurs complémentaires dans la tarification. L'erreur quadratique moyenne du modèle multiple est de 9,86 \$.

Interprétation :

- Dans le modèle simple, chaque mile supplémentaire augmente le prix de 2,43 \$ (facteur dominant).
- La durée seule contribue 0,01536 \$ par seconde ($\approx$ 0,92 \$/min).
- Dans le modèle multiple, le coefficient de L (1,90 \$/mile) et celui de D (0,36 \$/min) sont plus faibles que dans les modèles simples, car L et D sont corrélées : une partie de l'effet de la durée est déjà portée par la distance. Le terme en D capte la tarification à l'attente (embouteillages).
- L'intercept (5,45 \$) correspond aux frais fixes de prise en charge (*flag drop*), auxquels s'ajoutent les pourboires et suppléments inclus dans `trip_total`.

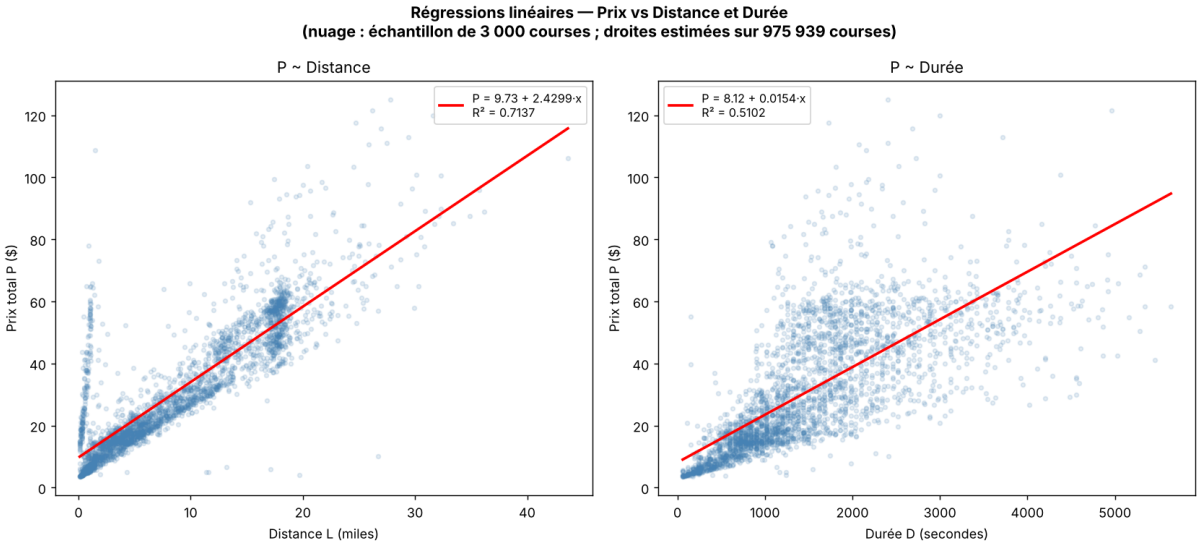


Figure 3 : Nuages de points (échantillon de 3 000 courses) et droites de régression : $P \sim L$ (gauche) et $P \sim D$ (droite)

5.3. Question 3 : Plages horaires et plage de pointe

Table 7 : Prix moyen et volume de courses par plage horaire

Plage horaire	Courses	Part	Prix moyen (\$)	Écart-type (\$)
[00h–04h[	69 750	7,2 %	**24,69**	18,78
[04h–08h[	72 008	7,4 %	32,32	19,15
[08h–12h[	178 403	18,3 %	30,72	20,02
[12h–16h[	226 644	23,2 %	**32,95**	20,03
[16h–20h[	**254 812**	26,1 %	30,73	20,05
[20h–00h[	174 322	17,9 %	30,38	20,32

ANOVA : $F = 1\,936{,}64$, $p \approx 0$, $\eta^2 = 0{,}0098$ $\Rightarrow$ Rejet de H_0
Corrélation : $r(P, \text{slot}) = 0{,}032$, $p = 8{,}17 \times 10^{-219}$

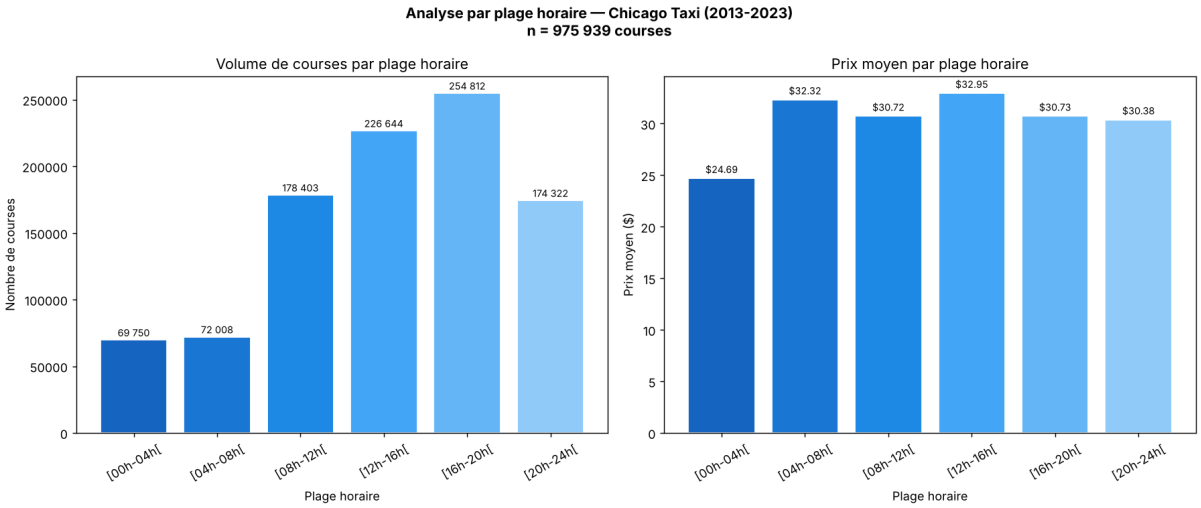


Figure 4 : Volume de courses (gauche) et prix moyen (droite) par plage horaire de 4 h

L'ANOVA ($F = 1\,936{,}64$, $p \ll 0{,}05$) rejette H_0 : les moyennes de prix diffèrent significativement entre les 6 plages. Cependant, $\eta^2 = 0{,}0098$: la plage horaire n'explique qu'environ 1,0 % de la variance du prix, qui dépend avant tout de la distance (question 2).

La plage **[16h–20h[** concentre le plus grand volume de courses (254 812, soit 26,1 % du total) : c'est la **plage de pointe** en termes d'activité (retours domicile-travail). Le prix moyen est le plus élevé en [12h–16h[(32,95 $) et minimal la nuit, en [00h–04h[(24,69 $).

La corrélation linéaire $r(P, \text{slot}) = 0{,}032$ est très faible mais significative ($p = 8{,}17 \times 10^{-219}$) : la relation entre le prix et la plage n'est **pas linéaire monotone**, le prix n'augmente pas régulièrement avec l'heure. L'ANOVA est donc plus appropriée que la corrélation seule.

5.4. Test post-hoc de Bonferroni

L'ANOVA ayant rejeté H_0, il est nécessaire de déterminer quelles paires de plages horaires diffèrent significativement. On applique le **test post-hoc de Bonferroni** : pour chacune des $\binom{6}{2} = 15$ paires, un test t de Welch (variances inégales) est réalisé, puis la p-valeur brute est corrigée par multiplication par 15 :

$$p_{\text{adj}} = \min(p_{\text{brut}} \times 15,\ 1), \qquad \alpha_{\text{adj}} = \frac{0{,}05}{15} \approx 0{,}0033.$$

Table 8 : Résultats du test post-hoc de Bonferroni — 15 paires de plages horaires

Plage i	**Plage j**	$\Delta\bar{P}$ **(\$)**	t	p_{adj}	**Sig.**
[00h–04h[	[04h–08h[	−7,64	−75,81	≈ 0	***
[00h–04h[	[08h–12h[	−6,04	−70,65	≈ 0	***
[00h–04h[	[12h–16h[	−8,26	−100,01	≈ 0	***
[00h–04h[	[16h–20h[	−6,04	−74,18	≈ 0	***
[00h–04h[	[20h–00h[	−5,69	−66,07	≈ 0	***
[04h–08h[	[08h–12h[	+1,60	+18,66	$2{,}11 \times 10^{-76}$	***
[04h–08h[	[12h–16h[	−0,63	−7,56	$5{,}90 \times 10^{-13}$	***
[04h–08h[	[16h–20h[	+1,59	+19,52	$1{,}43 \times 10^{-83}$	***
[04h–08h[	[20h–00h[	+1,94	+22,50	$9{,}49 \times 10^{-111}$	***
[08h–12h[	[12h–16h[	−2,22	−35,10	$3{,}14 \times 10^{-268}$	***
[08h–12h[	[16h–20h[	−0,00	−0,06	1	n.s.
[08h–12h[	[20h–00h[	+0,35	+5,08	$5{,}63 \times 10^{-6}$	***
[12h–16h[	[16h–20h[	+2,22	+38,38	≈ 0	***
[12h–16h[	[20h–00h[	+2,57	+39,95	≈ 0	***
[16h–20h[	[20h–00h[	+0,35	+5,56	$4{,}15 \times 10^{-7}$	***

*** $p_{\text{adj}} < 0{,}001$ n.s. : non significatif $\Delta\bar{P} = \bar{P}_i - \bar{P}_j$ Test t de Welch bilatéral, $n = 975\,939$

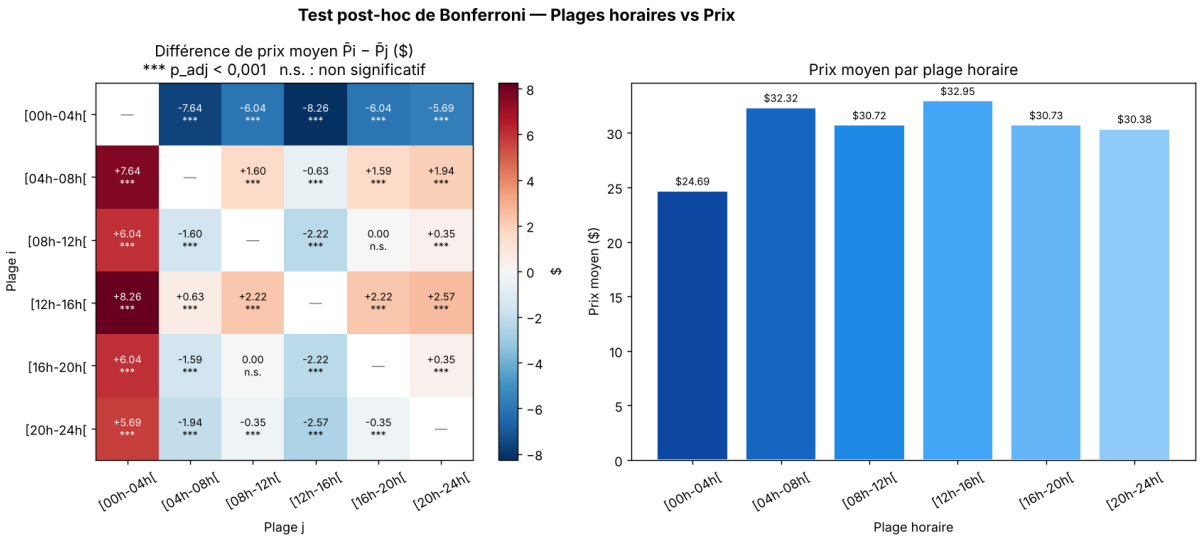


Figure 5 : Matrice des différences de prix moyen (gauche) et prix moyen par plage (droite) — test post-hoc de Bonferroni

Résultat : 14 paires sur 15 sont significativement différentes après correction. Plusieurs points ressortent :

- La plage [00h–04h[est isolée : son prix moyen (24,69 \$) est inférieur à toutes les autres plages d'au moins 5,69 \$ (écart maximal de 8,26 \$ avec [12h–16h[).
- La plage [12h–16h[affiche le prix moyen le plus élevé (32,95 \$), significativement supérieur à toutes les autres ($p_{\text{adj}} \ll 0{,}05$).
- Les plages [08h–12h[et [16h–20h[**ne diffèrent pas** significativement ($\Delta\bar{P} = -0{,}004$ \$, $p_{\text{adj}} = 1$) : leurs prix moyens sont identiques.

- Les autres petites différences (ex. [08h–12h[vs [20h–00h[: $\Delta = +0{,}35\,\$$) restent significatives, ce qui s'explique par la taille d'échantillon exceptionnelle ($n \approx 10^6$) et la puissance statistique très élevée qui en découle.

6. Conclusion

Cette étude sur 975 939 courses de taxi de Chicago (2013–2023) met en évidence trois résultats principaux :

1. **Test d'hypothèse (Q1) :** les moyennes de P, D et L en 2021 diffèrent significativement de la référence 2013–2020 : prix +18,8 % ($t = 87{,}05$), durée +5,8 % ($t = 32{,}47$), distance +14,4 % ($t = 55{,}41$). Les tailles d'effet sont toutefois faibles ($d \leq 0{,}28$), et la comparaison avec 2019 montre que les niveaux de 2021 sont proches de ceux d'avant la pandémie (prix −1,0 %). La hausse reflète donc surtout la tendance de long terme 2013–2019 ; le seul effet propre à 2021 est une durée plus courte à distance égale.
2. **Régression (Q2) :** le prix est fortement corrélé à la distance ($r = 0{,}845$, $R^2 = 0{,}714$). La durée est un facteur complémentaire ($r = 0{,}714$). Le modèle multiple donne $R^2 = 0{,}758$:

$$\hat{P} \approx 5{,}45 + 1{,}902 \cdot L + 0{,}005994 \cdot D$$

   La tarification repose principalement sur la distance (1,90 \$/mile), complétée par un tarif horaire (0,36 \$/min) qui capte les embouteillages.
3. **Plages horaires (Q3) :** l'ANOVA ($F = 1\,936{,}64$, $p \ll 0{,}05$) confirme des différences significatives entre les 6 plages, mais d'ampleur limitée ($\eta^2 = 0{,}0098$). La plage [16h–20h[est la plage de pointe en volume (254 812 courses, 26,1 %) et [12h–16h[la plage au prix maximal (32,95 \$). La plage nocturne [00h–04h[a un prix significativement inférieur à toutes les autres (24,69 \$). Le test de Bonferroni montre que 14 paires sur 15 diffèrent ; seules [08h–12h[et [16h–20h[ont des prix équivalents. La corrélation $r(P, \text{slot}) = 0{,}032$ confirme que la variation du prix selon l'heure n'est pas monotone.

6.1. Limites de l'étude

- **Échantillonnage :** l'étude porte sur un échantillon d'environ 108 000 courses par an, et non sur la population complète. En 2013, 64 % des courses ont été éliminées (distance ou durée non renseignée), il n'en reste que 39 664 : les premières années sont moins bien représentées.
- **Référence hétérogène :** la période 2013–2020 regroupe des années dont les niveaux de prix sont très différents ; la comparaison 2021 vs 2019 est plus pertinente pour isoler l'effet de 2021.
- **Significativité et taille d'effet :** avec près d'un million d'observations, presque toute différence est significative ; les conclusions s'appuient donc aussi sur d et η^2.
- **Variable prix :** `trip_total` inclut le pourboire, les péages et les suppléments, ce qui ajoute de la variabilité non expliquée par L et D.
- **Modèle linéaire :** les distributions sont asymétriques et bimodales (trajets vers les aéroports) et les résidus ne sont pas homoscédastiques ; la régression est utilisée ici dans un but descriptif.